



Máster Universitario en Visión Artificial

SD-SLAM+: Mejora de un algoritmo de Visual SLAM mediante información de profundidad con cámara RGBD

Memoria del Trabajo Fin de Máster en Visión Artificial

Autor: Omar Garrido Martín

Tutores:

Jose María Cañas Plaza

Diego Martín Martín

Junio 2020

Resumen

TODO

TODO

TODO

Índice general

1. Introducción	1
1.1. Visión artificial	1
1.2. SLAM	1
1.3. Cámaras de profundidad	1
1.4. Estructura del documento	1
2. Objetivos	3
2.1. Descripción del problema	3
2.2. Objetivos	3
2.3. Requisitos	3
3. Estado del arte	5
3.1. SLAM con información Visual (RGB)	5
3.2. SLAM con información Visual (RGBD)	5
3.3. SLAM con solo información de profundidad	5
4. Mejoras sobre SD-SLAM	7
4.1. Introducción	7
4.2. ROSificación de DIFODO	7
4.3. Herramienta odometry_evaluation_file_creator	7
4.4. Uso de DIFODO cuando SD-SLAM falla	8
4.5. Diseño del paso de DIFODO de vuelta a SD-SLAM	8
5. Experimentos	9
5.1. El conjunto de datos	9

5.1.1.	El error de trayectoria absoluto o ATE (Absolute Trajectory Error) . . .	10
5.2.	Evaluación de DIFODO	11
5.2.1.	Hiperparámetros, rendimiento y tiempos de procesamiento	11
5.2.2.	Conclusiones	17
5.3.	Comparativa entre DIFODO y SD-SLAM	17
5.3.1.	Experimentos	18
5.3.2.	Conclusiones	22
5.4.	SD-SLAM frente a SD-SLAM+	22
5.4.1.	El conjunto de datos	22
5.4.2.	Experimento: DIFODO como apoyo a SD-SLAM	23
5.4.3.	Experimento: Rendimiento de SD-SLAM+ en entornos difíciles	29
5.4.4.	Experimento: Rendimiento de SD-SLAM+ en entornos con zonas de baja textura	39
5.4.5.	Evaluación de tiempo de procesamiento	41
5.4.6.	Conclusiones	43
6.	Conclusiones	45
6.1.	Objetivos conseguidos	45
6.2.	Discusión	45
6.3.	Trabajos futuros	45
	Bibliografía	47

Índice de figuras

5.1. Traectorias de los algoritmos para la secuencia <i>floor</i> en el programa slam-testbed. En verde se muestra el <i>ground-truth</i> , en azul la trayectoria estimatda en cada caso. La figura (a) corresponde a la estimación de DIFODO y la figura (b) a la la estimación de SD-SLAM.	20
5.2. SD-SLAM aplicado en rgbd_dataset_freiburg1_desk.bag	23
5.3. Traectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el <i>ground-truth</i> , en azul la trayectoria estimatda en cada caso. Las figura (a) corresponde a la versión original de SD-SLAM y la figura (b) a la versión modificada de SD-SLAM, SD-SLAM+	25
5.4. Traectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el <i>ground-truth</i> , en azul la trayectoria estimatda en cada caso. Las figura (a) corresponde a la estimación de SD-SLAM+ en el test 2 y la figura (b) a la la estimación de SD-SLAM+ en el test 4.	29
5.5. SD-SLAM aplicado en rgbd_dataset_freiburg3_nostructure_texture_far.bag	30
5.6. Final de la secuencia rgbd_dataset_freiburg3_nostructure_texture_far.bag .	31
5.7. Traectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el <i>ground-truth</i> , en azul la trayectoria estimatda en cada caso. Las figura (a) corresponde a la estimación de SD-SLAM y la figura (b) a la la estimación de SD-SLAM+.	33
5.8. Traectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el <i>ground-truth</i> , en azul la trayectoria estimatda en cada caso. Las figura (a) corresponde a la estimación de SD-SLAM y la figura (b) a la la estimación de SD-SLAM+.	34

5.9. Traectorias y reconstrucción de los algoritmos en la interfaz SD-SLAM. Las figura (a) corresponde a D-SLAM y la figura (b) a SD-SLAM+.	35
5.10. Traectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el <i>ground-truth</i> , en azul la trayectoria estimatda en cada caso. Las figura (a) corresponde a la estimación de SD-SLAM+ para el test 6 y la figura (b) a la la estimación de SD-SLAM+ para el test 7.	37
5.11. Comparativa de las traectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el <i>ground-truth</i> , en azul la trayectoria estimatda en cada caso.	38
5.12. Momento en el cual la textura decae en la secuencia rgbd_dataset_freiburg3_floor.bag . Imagen perteneciente a la GUI de SD-SLAM+	39
5.13. Comparativa de las traectorias y reconstrucción de los algoritmos SD-SLAM y SD-SLAM+.	41
5.14. Comparativa del tiempo de procesamiento por imagen para la secuencia rgbd_dataset_freiburg3_flo	

Índice de tablas

5.1. Tiempos de procesamiento para distintas resoluciones y distintos procesadores .	13
5.2. RMSE para el ATE (Absolute Trajectory Error) en distintas resoluciones de DIFODO.	14
5.3. Tiempos de procesamiento para distintos niveles de pirámide en AMD-FX 8370	15
5.4. Comparación de tiempos de procesamiento para distintos niveles de pirámides y procesadores.	16
5.5. RMSE para el ATE (Absolute Trajectory Error) en distintos niveles de piramide de DIFODO.	17
5.6. Comparación del ATE (Absolute Trajectory Error) en DIFODO y SD-SLAM para secuencias de freiburg 1.	18
5.7. Comparación del ATE en DIFODO y SD-SLAM para secuencias de freiburg 3: Estructura vs Textura. En verde el menor error en cada secuencia.	21
5.8. Comparación del ATE en el Test 1: SD-SLAM vs SD-SLAM+	24
5.9. Comparación del ATE en el test 2: SD-SLAM vs SD-SLAM+	26
5.10. Test 2: Evolución del ATE en SD-SLAM+	26
5.11. Comparación del ATE en el test 3: SD-SLAM vs SD-SLAM+	27
5.12. Test 3: Evolución del ATE en SD-SLAM+	27
5.13. Comparación del ATE en el Test 4: SD-SLAM vs SD-SLAM+	28
5.14. Test 4: Evolución del ATE en SD-SLAM+	28
5.15. Comparación del ATE en el test 5: SD-SLAM vs SD-SLAM+	31
5.16. Comparación del ATE en el test 6: SD-SLAM vs SD-SLAM+	33
5.17. Test 6: Evolución del ATE en SD-SLAM+	36
5.18. Comparación del ATE en el test 7: SD-SLAM vs SD-SLAM+	36

5.19. Test 8: Evolución del ATE en SD-SLAM+	38
5.20. Comparación del ATE en el test 9: SD-SLAM vs SD-SLAM+	40

Capítulo 1

Introducción

TODO:Some intro

1.1. Visión artificial

1.2. SLAM

1.3. Cámaras de profundidad

1.4. Estructura del documento

Capítulo 2

Objetivos

2.1. Descripción del problema

2.2. Objetivos

2.3. Requisitos

- Tiempo de procesamiento real: 33.3 ms o 30 imágenes por segundo, idealmente en procesadores no muy exigentes.
- Algoritmo capaz de estimar nuevas posiciones a partir de información de profundidad únicamente.

2.3. REQUISITOS

Capítulo 3

Estado del arte

TODO: Que se va a analizar, de que va la seccion

3.1. SLAM con información Visual (RGB)

3.2. SLAM con información Visual (RGBD)

3.3. SLAM con solo información de profundidad

Capítulo 4

Mejoras sobre SD-SLAM

TODO: Que se va a analizar, de que va la seccion

4.1. Introducción

Hablar de porque vamos a integrar SD-SLAM con DIFODO, hacer referencias a experimentos donde se comparen ambos, etc .En base a las conclusiones llegadas anteriormente cual es la mejor forma o el camino a la hora de integrar ambos algoritmos

4.2. ROSificación de DIFODO

porque hace falta rosificar difodo. para hacer experimentos y evaluarlo contra sd-slam asi como para preparar el terreno de cara a la integracion pues sd-slam esta reosificado.

4.3. Herramienta odometry_evaluation_file_creator

Necesidad de crear una herramienta que permita transformar el sistema de referencia de cada algoritmo al de la secuencia y crea un fichero compatible para la evaluación

<https://roboticslaburjc.github.io/2019-tfm-omar-garrido/entries/entry13/>

4.4. Uso de DIFODO cuando SD-SLAM falla

4.5. Diseño del paso de DIFODO de vuelta a SD-SLAM

Capítulo 5

Experimentos

A lo largo del desarrollo de este proyecto, se han realizado numerosos estudios sobre distintos algoritmos con diferentes objetivos. En esta sección se detallan en profundidad estos, aunque primero se detallan las características del set de datos usado durante la mayoría de experimentos.

5.1. El conjunto de datos

El conjunto de datos que se necesita para evaluar estos algoritmos necesita de unas características específicas. Se necesita de un conjunto de datos que provenga de un sistema de cámaras con información tanto de color o RGB como de información de profundidad o D de *depth*, profundidad. Estas son las características de la cámara utilizada como apoyo durante el desarrollo de este proyecto, la realsense D435.

El conjunto de datos **RGB-D SLAM Dataset and Benchmark** [4] cumple las características necesarias. Este *dataset* de la universidad técnica de Munich (Technical University of Munich or TUM), es un dataset de más de 50 secuencias de videos grabados con una cámara kinect v1. Las secuencias están formadas por secuencias de video RGBD con una resolución de 640x480 pixeles a una frecuencia de 30Hz. Las secuencias cuentan con poses consideradas como el *ground-truth* que puede ser usadas para comparar las estimaciones de los algoritmos usados. También cuenta con información del acelerómetro incorporado de la kinect aunque este no es usado en este proyecto, así como parámetros de calibración de la cámara o parámetros intrínsecos en caso de ser necesarios. En el caso de SD-SLAM estos parámetros son necesarios.

5.1. EL CONJUNTO DE DATOS

El *dataset* se realiza sobre interiores, en habitaciones de oficina, dentro de la propia universidad, y presentan numerosos entornos con características distintas que lo hacen ideal para la comparación de ambos algoritmos. Una de estas características es la de contar con secuencias sin textura, secuencias sin estructura y secuencias que no cuentan con textura ni estructura. Las distintas secuencias están disponibles en dos formatos:

- Como un conjunto de imágenes que pueden ser cargadas desde disco.
- Como *roslab*, un formato utilizado en el ámbito de ROS.

El formato usado en la realización de este proyecto ha sido el de ROS ya que ambos algoritmos DIFODO y SD-SLAM han sido preparados para trabajar con este formato debido a sus sencillez a la hora de integrar.

5.1.1. El error de trayectoria absoluto o ATE (Absolute Trajectory Error)

Entre las distintas formas de evaluar dos trayectorias para evaluar cual es la diferencia entre ellas hay dos que destacan y que se han popularizado entre los algoritmos de SLAM, son el ATE y el RPE [4]. El ATE o error de trayectoria absoluto está más enfocado en medir el rendimiento de algoritmos de visual SLAM. Por otro lado, en contraste el RPE o error de posición relativa está más enfocado en medir el rendimiento de algoritmos de odometría visual. El ATE primero hace un alineamiento de ambas trayectorias en caso de ser necesario, para luego evaluar la diferencia absoluta entre cada una de la posiciones de ambas trayectorias. En el cálculo de la diferencia entre poses solo se usa la traslación y no la orientación y, aunque pueda parecer que se está perdiendo la información de la orientación, esta se ve al final introducida ya que un error en la orientación se acaba traduciendo en un error en la posición en el espacio. El RPE lo que calcula son diferencias en el movimiento entre dos instantes temporales o sellos temporales al ser las estimaciones una señal no continua. El RPE puede y suele calcularse usando como unidad las estimaciones con cada nueva imagen. Se puede comparar el movimiento entre imágenes consecutivas, o cada X intervalo de imágenes. Al ser SD-SLAM un algoritmo como su propio nombre indica de visual SLAM, la métrica elegida en este trabajo para comparar SD-SLAM y su nueva versión SD-SLAM+ es ATE.

5.2. Evaluación de DIFODO

DIFODO es la piedra angular de esta mejora sobre SD-SLAM pero para evaluar si su integración tenía sentido, se tuvieron que realizar una serie de experimentos que analizarían su rendimiento y tiempos de procesamiento en función de cada uno de los hiperparámetros que permite modificar el algoritmo. Tras la realización de estos experimentos se establecieron unas conclusiones que son las que llevaron a integrarlo con SD-SLAM para mejorarlo. Esta sección detalla esos experimentos.

5.2.1. Hiperparámetros, rendimiento y tiempos de procesamiento

DIFODO cuenta con una serie de hiperparámetros que permiten modificar como se comporta el algoritmo [2]. Estos parámetros afectan principalmente a la estimación de la odometría pero también hay algunos parámetros que afectan al tiempo de procesamiento. El parámetro que más afecta a la estimación de forma directa y también al tiempo de procesamiento es el número de imágenes usadas en la pirámide de imágenes. Por otro lado la resolución de entrada de las imágenes, a pesar de no ser un parámetro directo de DIFODO, afectan en gran medida al rendimiento y tiempo de procesamiento del algoritmo por lo que también se estudiará en esta sección.

El tiempo de procesamiento es uno de los puntos más importantes de cara a cumplir con el requisito de tiempo real para el nuevo algoritmo desarrollado SD-SLAM+. Es por eso que es clave su estudio en DIFODO. En función del artículo original [2], DIFODO es capaz de funcionar a 60Hz en un procesador de un solo núcleo. Aunque no se especifica en que resolución, más adelante se observarán los tiempos expuestos en el artículo de DIFODO así como los obtenidos experimentalmente.

Durante el desarrollo de este trabajo, se dió la casualidad de que en un punto intermedio el hardware sobre el que se estaba desarrollando se vió sustituido por uno más actual. Esto ha permitido que se obtengan tiempos en el procesamiento de DIFODO tanto para el hardware antiguo como para el nuevo. DIFODO principalmente utiliza el procesador en su implementación, aunque la memoria RAM y la placa base afectarán al rendimiento en cierta medida, se va a utilizar el procesador como referencia en este estudio. La CPU más antigua era el modelo AMD FX-8370, una CPU del Q3 de 2014 que cuenta con 8 Cores, 8 Threads a una frecuencia

5.2. EVALUACIÓN DE DIFODO

de 4.0GHz. La nueva CPU es un AMD Ryzen 5 2600, una arquitectura más nueva del segundo cuarto de 2018 que cuenta con 6 Cores, 12 Threads a una frecuencia de 3.4GHz. El AMD FX-8370 es una CPU que en su día estuvo considerado alta gama mientras que el ryzen 5 2600 es una gama media. Cuatro años separan a estos procesadores, siendo el Ryzen 5 uno de los procesadores más usados actualmente en el ámbito *gaming* por su relación calidad precio.

Por otro lado, también se cuenta con información de tiempos en el artículo original así como de la CPU utilizada, un Intel Core i7-3820 del final de 2013 con 4 Cores, 8 Threads y frecuencia de 3.6 GHz. Un procesador cuyo ciclo de vida coincidió con el del AMD-FX 8370 por lo que será útil para comparar estos tiempos.

Efecto de la resolución

La resolución afecta al rendimiento de DIFODO y a la estimación de la odometría. Los resultados mostrados en el artículo original [2], muestran como a mayor resolución, mayor es la precisión de la estimación así como el tiempo de procesamiento. Se han realizado una serie de experimentos sobre el mismo conjunto de datos pero usando la versión de DIFODO integrada con ROS que es como finalmente funcionará el algoritmo.

La tabla 5.1 muestra los tiempos de procesamiento de DIFODO a distintas resoluciones para los distintos procesadores. En ella se observa como se ha conseguido una reducción en el tiempo de procesamiento de casi un factor de 3 para la nueva CPU, el Ryzen 5 2600. Para las resoluciones menores a 320x240 el tiempo de procesamiento es menor que 33.3ms, tanto para la nueva CPU como la antigua, por lo que DIFODO a esas resoluciones funciona a tiempo real, cumpliéndose el requisito de procesamiento en tiempo real a 30 imágenes por segundo. Esto es de especial importancia pues uno de los objetivos de este trabajo es conseguir un algoritmo que funcione en tiempo real. La resolución VGA presenta tiempos superiores al límite de los 33.3ms por lo que no se podrían considerar en casos donde la CPU no sea especialmente potente.

Resolución	Ryzen 5 2600	AMD-FX 8370	Intel Core i7-3820
40x30	-	-	3.85ms
80x60	-	-	5.18ms
160x120	3.5ms	9ms	10.04ms
320x240	12.75ms	30ms	28.61ms
640x480	55.5ms	130ms	-

Tabla 5.1: Tiempos de procesamiento para distintas resoluciones y distintos procesadores

En cuanto a la relación tiempo/resolución, se observa una clara tendencia donde cada vez que se aumenta en dos veces la resolución, cuatro veces si nos basamos en el número de píxeles totales, el tiempo de procesamiento aumenta de forma exponencial. Resoluciones similares o mayores a VGA se tienen que descartar si no se cuenta con un procesador de gran potencia o si se pretende trabajar a tiempo real o 30 imágenes por segundo, algo crucial en los algoritmos de SLAM ya que el trabajar a menor tasa de imágenes por segundos dificulta la tarea de la estimación de la pose al presentar mayor desplazamiento entre imágenes.

En cuanto a los tiempos obtenidos, se puede observar como los tiempos expuesto en el artículo original son correctos puesto que los procesadores antiguos, AMD-FX 8370 e Intel Core i7-3820 son de un rendimiento similar y se obtienen tiempos similares. No se han realizado experimentos de tiempos a resoluciones menores como si que se hizo en el artículo original ya que no tiene sentido ir mucho más abajo en resolución pues a 160x120 hay mucho espacio hasta llegar a los 33.3ms, lo que si se ha hecho es comprobar que a resoluciones algo más grandes como VGA, el tiempo real deja de ser posible.

Una vez se han observado los tiempos de procesamiento, se puede concluir que DIFODO es un algoritmo que puede integrarse junto a SD-SLAM al menos en cuanto al requisito de procesamiento en tiempo real, el siguiente paso es observar como afecta la resolución a la estimación de la pose.

Lo esperado en base a los resultados del artículo original [2], es que el algoritmo a mayor resolución tenga un menor error en la estimación de la pose. La siguiente tabla 5.2 muestra el error de trayectoria absoluto para distintas resoluciones para distintas secuencias del conjunto de datos. En rojo se muestra la resolución que consigue el mayor error y en verde la que consigue el menor. La resolución que parece obtener mejores resultados de forma general es la resolu-

5.2. EVALUACIÓN DE DIFODO

ción QVGA (320x240). Mientras que los peores resultados se obtienen en la mayor resolución 640x480. Estos resultados son a priori, contrarios a lo esperado y las conclusiones del artículo original, donde se espera que a mayor resolución, menor sea el error. Sin embargo, esto tiene una explicación que tiene que ver con el diseño de la rosificación de DIFODO que se ha usado para evaluar el algoritmo. Este software está diseñada para trabajar a la mayor frecuencia de imágenes posible o bien se puede fijar una frecuencia objetivo. En este caso, la frecuencia de las secuencias de video del conjunto de datos es de 30 imágenes por segundo, lo que implica que la máxima frecuencia está limitada por la secuencia. Como se observó en la tabla anterior 5.1, las resoluciones 160x120 y 320x240 pueden trabajar a 30 imágenes por segundo sin problema, incluso a frecuencias mayores, pero la resolución 640x480 apenas llega a las 20 imágenes por segundo. Esto produce que 1 de cada 3 imágenes se pierdan al no poder seguir DIFODO 640x480 la tasa de imágenes por segundo de la secuencia, provocando una pérdida de información que se traduce en un desplazamiento mayor entre las imágenes sobre la que estimar la odometría que afecta de forma negativa a la estimación del algoritmo.

Secuencia	160x120	320x240	640x480
desk2	0.2620	0.2094	0.2026
floor	0.8663	0.8844	0.8814
360	0.4496	0.4339	0.5692
rpy	0.0793	0.1175	0.1318
xyz	0.0805	0.0613	0.0756
desk	0.1476	0.1441	0.1573
room	0.4131	0.3705	0.4839
Total	2.2984	2.2211	2.5018

Tabla 5.2: RMSE para el ATE (Absolute Trajectory Error) en distintas resoluciones de DIFODO.

Efecto del nivel de la pirámide

DIFODO utiliza una pirámide de imágenes, donde la imagen de mayor resolución es la imagen original y las imágenes sucesivas se submuestrean, obteniendo lo que es conocido como pirámide de imágenes en visión artificial. Este mecanismo se utiliza para aplicar algoritmos de procesamiento a distintos niveles de resolución para después juntar la información obtenida

en distintos niveles, obteniendo resultados mucho mejores que en la evaluación a una única resolución, esta técnica se uso en el cálculo del flujo óptico [1]. En este caso, DIFODO también la usa pero para el cálculo del *range flow* [3], técnica derivada del flujo óptico para ser aplicada en imágenes de profundidad en lugar de RGB. Esta pirámide le permite observar tanto movimientos de pequeños objetos como de objetos más grandes, lo que le permite obtener una mejor estimación que usando solo la imagen original. Esto afecta directamente a la estimación obtenida y también al tiempo de procesamiento, pues a menor número de imágenes en la pirámide menos es la cantidad de veces que se tendrá que calcular el *range flow*.

De nuevo se analiza tanto a nivel de tiempos como a nivel de error en la estimación el efecto de este parámetro.

Resolución	Niveles de Pirámide	Tiempo (ms)
160x120	1	4
160x120	3	8.5
160x120	5	9
320x240	1	15
320x240	3	27
320x240	5	30
640x480	1	80
640x480	3	130
640x480	5	130

Tabla 5.3: Tiempos de procesamiento para distintos niveles de pirámide en AMD-FX 8370

En la tabla 5.3 se puede apreciar como disminuye el tiempo en función del nivel de la pirámide usado en cada momento. Como se puede apreciar, la diferencia entre calcular 3 o 5 niveles es casi despreciable. La razón es que en cada nuevo nivel se está reduciendo la imagen original a la mitad del tamaño original. Se consigue pues un efecto similar al de elevar al cuadrado de forma continua. Por ejemplo, para la resolución de 640x480 los niveles del resto de la pirámide serían 320x240, 160x120, 80x40 y 40x20 respectivamente. Los últimos dos niveles de la pirámide son muy pequeños en comparación con el primer nivel por lo que la diferencia entre usar 3 y 5 niveles es computacionalmente despreciable. Sin embargo, el usar únicamente la imagen

5.2. EVALUACIÓN DE DIFODO

de entrada supone un ahorro computacional de en torno al 50 %. Finalmente en la tabla 5.4 se aprecia como la disminución de tiempos con la nueva CPU mantiene la proporción de 3 veces inferior, independientemente del número de niveles de la pirámide.

Resolución	Niveles de Pirámide	AMD-FX 8370	AMD Ryzen 5 2600
320x240	1	15ms	5.85ms
320x240	3	27ms	12.29ms
320x240	5	30ms	12.75ms

Tabla 5.4: Comparación de tiempos de procesamiento para distintos niveles de pirámides y procesadores.

Se ha visto como la diferencia entre usar 3 o 5 niveles de pirámide es computacionalmente despreciable, mientras que se ahorra un 50 % de tiempo si solo usamos un nivel. La siguiente duda a resolver es comprobar si esto es así también para la estimación de la pose.

Mediante un rápido vistazo a la tabla 5.5 se puede apreciar claramente que a mayor número de imágenes en la pirámide menor el error cometido en la estimación de la pose. La diferencia es muy notable cuando se usa un solo nivel de pirámide siendo el error total en torno a 2.5 veces mayor que cuando se usan 5 niveles, como era de esperar pues una única resolución solo es capaz de encontrar movimientos muy locales y no globales o grandes en la imagen de profundidad. Solo hay una secuencia donde los resultados son muy parejos en los 3 casos, en la secuencia titulada *floor*. Esta secuencia además presenta un error muy alto comparado con el resto de secuencias, esto es así puesto que como la secuencia indica, es una secuencia donde la cámara mira al suelo. Esto produce que haya una ausencia de estructura en la imagen lo que dificulta a DIFODO la estimación. Es el caso equivalente a una escena que es homogénea en los niveles de intensidad de sus píxeles para el cálculo del flujo óptico. Independientemente del nivel de pirámide no se puede hacer una estimación precisa y los nuevos niveles de pirámide no aportan información al no haber estructura ya sea de objetos pequeños o grandes.

Secuencia	1	3	5
desk2	1.1880	0.2955	0.2094
floor	0.8877	0.9473	0.8844
360	1.204	0.6992	0.4339
rpy	0.3438	0.1496	0.1175
xyz	0.1165	0.0645	0.0613
desk	0.7288	0.2997	0.1441
room	1.2819	0.4188	0.3705
Total	5.7507	2.8746	2.2211

Tabla 5.5: RMSE para el ATE (Absolute Trajectory Error) en distintos niveles de piramide de DIFODO.

5.2.2. Conclusiones

Se ha comprobado como DIFODO es un algoritmo capaz de funcionar a 30 imágenes por segundo en procesadores no muy exigentes e incluso a mucha mayor frecuencia en otros procesadores o a resoluciones inferiores sin comprometer la estimación de la pose. Cumple pues, con la necesidad de trabajar a tiempo real.

Por otro lado, se observa como las estimaciones de DIFODO son bastante buenas siempre y cuando haya suficiente estructura en la escena. Una comparación más exhaustiva del error cometido se verá en el siguiente capítulo donde se le compara con SD-SLAM.

5.3. Comparativa entre DIFODO y SD-SLAM

En esta sección se hace una evaluación cuantitativa de el algoritmo DIFODO y de SD-SLAM. Hay que tener en cuenta que DIFODO es un algoritmo unicamente de odometría visual, por lo que se obtiene una estimación con cada nueva imagen. Sin embargo SD-SLAM es un algoritmo de SLAM completo, esto quiero decir que no solo hace odometría o *tracking*, sino que hace mapeado también. Sin embargo lo más importante de cara a esta comparación es que el mapeado le permite hacer un seguimiento de aquellos lugares que se han visto previamente y usarlos para optimizar de forma global las siguientes estimaciones asi como las anteriores mediante el mecanismo de cierre de bucle. Esto le brinda una mayor capacidad en la estimación

5.3. COMPARATIVA ENTRE DIFODO Y SD-SLAM

de pose frente a DIFODO donde solo se utiliza la información de el frame actual y el anterior en las predicciones. Es de esperar, que SD-SLAM tengo un mejor rendimiento que DIFODO pues.

5.3.1. Experimentos

Para hacer esta comparación entre SD-SLAM y DIFODO se va a usar el software de SD-SLAM y le versión *rosificada* de DIFODO en conjunto con la herramienta descrita en la sección 4.3, *odometry_evaluation_file_creator*. El dataset para el estudio de nuevo es **RGB-D SLAM Dataset and Benchmark** [4] detallado anteriormente en la sección 5.1 Conjunto de datos. En cuanto a DIFODO, los parámetros usados durante la realización de estos experimentos ha sido de 320x240 de resolución y un nivel de pirámide de cinco niveles, pues se ha demostrado en la sección anterior, que es la mayor resolución que permite tiempo real de procesamiento y la que menor error presenta en la estimación.

Secuencia	DIFODO RMSE	SD-SLAM RMSE	Reducción del error (%)
desk2	0.2094	0.1716	18.01
floor	0.8844	0.3982	54.96
360	0.4339	0.3864	10.92
rpy	0.1175	0.0281	76.02
xyz	0.0613	0.0626	-2.27
desk	0.1441	0.1235	14.26
room	0.3705	0.2909	21.46
MEDIA	0.3173	0.2088	34.18

Tabla 5.6: Comparación del ATE (Absolute Trajectory Error) en DIFODO y SD-SLAM para secuencias de freiburg 1.

En la tabla 5.6 se evalua el error cometido por cada algoritmo en las secuencias de tipo *Freiburg 1*. Como era de esperar el error es menor en casi todos los casos para SD-SLAM en comparación con SD-SLAM. SD-SLAM reduce el error en la estimación de la pose en un 34 % de media en comparación con DIFODO para estas secuencias. Sin embargo hay una serie de datos a tener en cuenta. En muchas secuencias como *desk2*, *360*, *xyz*, *desk* la diferencia en la

estimación es mucho menor que ese 34 %, en torno a un 15-20 %, siendo muy parejos en ambos casos incluso llegando a ser superior DIFODO en la secuencia de *xyz*.

De entre todas estas secuencias hay dos *outliers* claros, que son la secuencia *floor* y *rpy*. En la secuencia *floor* la estimación contiene mucho error al no contar con apenas estructura como ya se discutió anteriormente en la sección 5.2.1. Se puede apreciar la mala estimación de DIFODO en la figura 5.1.

En el caso de la secuencia *rpy* la gran diferencia no es que DIFODO lo haga mal sino que SD-SLAM lo hace especialmente bien, de hecho es la secuencia donde SD-SLAM presenta un menor error de todas las presentadas al igual que DIFODO.

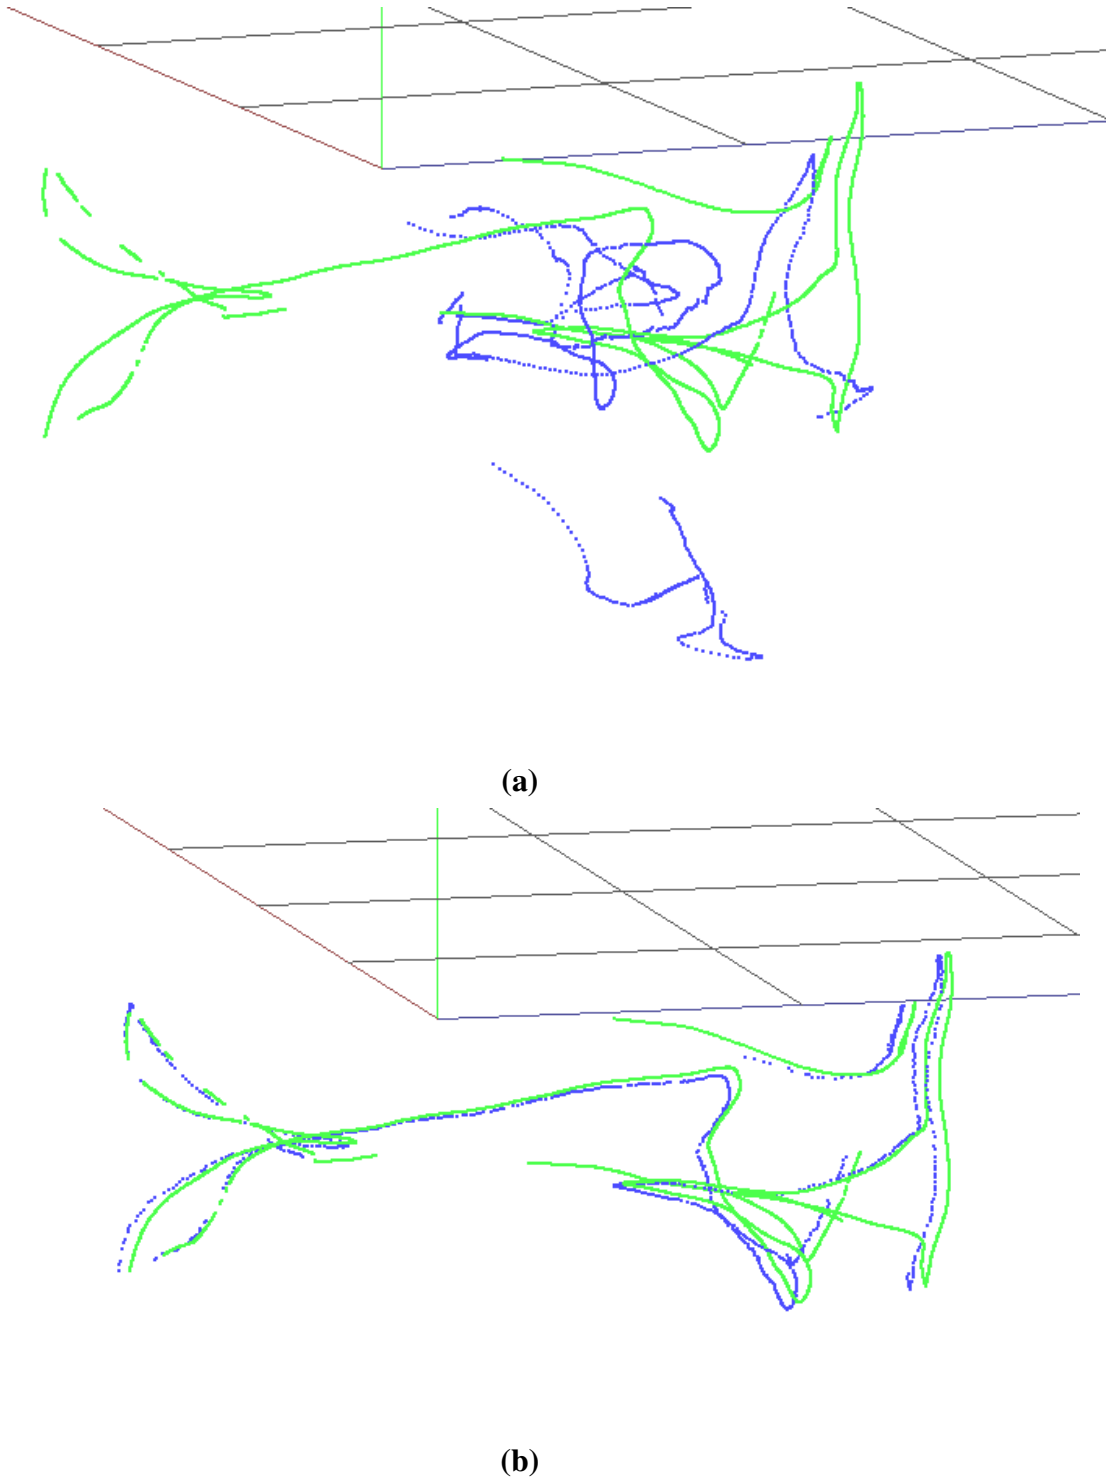


Figura 5.1: Trayectorias de los algoritmos para la secuencia *floor* en el programa slam-testbed. En verde se muestra el *ground-truth*, en azul la trayectoria estimada en cada caso. La figura (a) corresponde a la estimación de DIFODO y la figura (b) a la la estimación de SD-SLAM.

Tipo	Secuencia	DIFODO	SD-SLAM
Sin estructura	nostructure_texture_near	2.2992	0.0665
Sin Textura	structure_notexture_near	0.2903	2.005
Sin Textura	structure_notexture_far	0.2708	2.6243
Sin estructura/textura	nostructure_notexture_near_withloop	2.3351	2.2091
Sin estructura/textura	nostructure_notexture_far	1.9627	1.7486

Tabla 5.7: Comparación del ATE en DIFODO y SD-SLAM para secuencias de freiburg 3: Estructura vs Textura. En verde el menor error en cada secuencia.

En la tabla 5.7 se encuentran los resultados del error de la estimación pero en este caso para secuencias de la categoría *Freiburg 3*. Estas secuencias se caracterizan por contener secuencias más complejas y diversas. En la tabla se han dividido las secuencias por tipos que corresponden a:

- **Sin estructura:** Secuencias donde no hay información de estructura pero sí de textura.
- **Sin textura:** Secuencias donde no hay información de textura pero sí de estructura.
- **Sin estructura/textura:** Secuencias donde no hay información ni de estructura ni de textura.

Del tipo sin estructura, se ha evaluado la secuencia titulada *nostructure_texture_near*. Al no haber estructura el error de DIFODO es muy grande de más de 2m mientras que para SD-SLAM se consigue 0.06m de error, apenas unos centímetros.

Del tipo sin textura, se han evaluado dos secuencias, *structure_notexture_near* y *structure_notexture_far*. Al no haber textura SD-SLAM obtiene un error de varios metros, ya que en esas secuencias, SD-SLAM no consigue ni llegar a inicializar por lo que no se consigue si quiera una estimación de trayectoria. Por otro lado DIFODO lo hace en su línea de error al contar con suficiente información de estructura su estimación es similar a la encontrada en las secuencias anteriores. Finalmente hay un tipo donde no se cuenta con textura y tampoco con estructura, como es de esperar ambos algoritmos obtienen un error muy alto de en torno a los 2m.

En todos los casos el comportamiento y los resultados son los esperados, pues ambos algoritmos dependen de la información visual ya sea en textura o en profundidad.

5.3.2. Conclusiones

DIFODO ha demostrado ser un algoritmo de odometría visual con un buen rendimiento. SD-SLAM es de media un 20 % aproximadamente mejor que DIFODO en la estimación de la pose. DIFODO solo presenta mejor estimación de pose que SD-SLAM cuando hay poca textura visual. Sin embargo DIFODO, cuando no hay estructura no es capaz de ofrecer una buena estimación. Ambos algoritmos precisan pues, de información visual, en un caso textura y en el otro estructura. El uso de uno cuando el otro falla tiene sentido pues se puede utilizar como mecanismo de apoyo para no perder el *tracking*. Tiene sentido por los resultados vistos usar siempre que haya suficiente información visual SD-SLAM, pues de media, la estimación obtenida es mejor y se pueden usar otros mecanismos propios de un algoritmo de SLAM como el cierre de bucle. En aquellos casos donde no haya suficiente textura en la imagen y donde SD-SLAM normalmente se perdería o estimaría una mala posición, se usará DIFODO para suplir esta falta de información.

Se observa también que cuando no hay información ni de textura ni de estructura, el error en ambos algoritmos es muy alto, pero estamos hablando de el caso más difícil que pueden afrontar los algoritmos de visual SLAM. La solución en este caso sería utilizar información de otra fuente que no sea visual, como por ejemplo inercial.

5.4. SD-SLAM frente a SD-SLAM+

En esta sección se va a evaluar el error en la estimación de la pose para el algoritmo original, SD-SLAM y su evolución SD-SLAM+. Para ello se van a tener que simular modificaciones sobre el conjunto de datos originalmente usado y descrito en Sección 5.1.

5.4.1. El conjunto de datos

De nuevo el conjunto de datos usado es **RGBD TUM dataset** [4]. Sin embargo, a pesar de que el *dataset* contiene secuencias diversas como: secuencias de solo textura, secuencias de solo estructura, secuencias con textura y estructura, etc., no existe ninguna secuencia donde se tengan textura y estructura y, además, en algún momento se pierda la textura. Con el objetivo de probar el funcionamiento y el rendimiento del nuevo SD-SLAM+, es necesario simular pérdidas de

textura en las distintas secuencias. Para esto se ha creado una versión de ambos algoritmos con un nuevo parámetro en el fichero de configuración donde se pueden configurar los intervalos de tiempo donde se simulará esta pérdida de textura. Esto permite que el algoritmo en los intervalos configurados reciba imágenes RGB completamente negras, creando una matriz con la misma resolución que el resto de imágenes de la secuencia donde el valor de intensidad de todos los píxeles se encuentra a cero.

5.4.2. Experimento: DIFODO como apoyo a SD-SLAM

Estos experimentos se centran en la idea de demostrar que la integración de DIFODO en SD-SLAM, mejora al algoritmo original, dando lugar a SD-SLAM+. Para ello se han realizado una serie de test utilizando la misma secuencia de video y cambiando los intervalos donde se simula la pérdida de textura, para tener diferentes escenarios.

La secuencia usada es **rgbd_dataset_freiburg1_desk.bag**. Esta secuencia muestra una trayectoria semicircular a lo largo de dos escritorios de un laboratorio de la universidad de Munich como se puede apreciar en Figura 5.2.



Figura 5.2: SD-SLAM aplicado en **rgbd_dataset_freiburg1_desk.bag**

La trayectoria es de ida, yendo desde uno hacia el otro de los escritorios y luego vuelva por el mismo lado. Es por lo tanto una secuencia que permite relocalizaciones y cierres de bucles

en algoritmos de SLAM, al pasar por zonas que ya ha recorrido previamente. La secuencia es de 23.4 segundos de duración, sin embargo, aproximadamente los primeros 4 segundos de esta secuencia y del resto, carecen de imágenes. Esto es así para que a la hora de grabar el hardware tenga un tiempo de estabilización o calentamiento en el arranque, por lo que la duración real sería de 20 segundos aproximadamente. Cerca de la mitad de la secuencia se emplea en ir de un escritorio al otro y la otra mitad de la secuencia en volver, por lo que a partir de la segunda mitad de la secuencia se pueden producir cierres de bucles.

Test 1

- **Intervalos sin textura simulados (segundos):** [4-5]
- **Descripción:** Se ha simulado una pérdida de luz del segundo 4 al 5 con el objetivo de ver como el nuevo SD-SLAM+ es capaz de manejar esta situación en comparación a la versión anterior.

Version	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
SD-SLAM	1.2528	0.8894	0.1415	0.8823	0.0350	2.1653	866.4533
SD-SLAM+	0.1863	0.1673	0.1199	0.0820	0.0352	0.3153	19.1323

Tabla 5.8: Comparación del ATE en el Test 1: SD-SLAM vs SD-SLAM+

Los resultados de la anterior Tabla 5.8 muestran como el error de la nueva versión es mucho más pequeño que la versión original. Mientras que la versión original de SD-SLAM tiene un *rmse* de 1.25m la nueva versión, SD-SLAM+, tiene un *rmse* de 0.18m, un error 6 veces más pequeño en este caso. Estos resultados eran esperables pues como se aprecia en la Figura 5.3, en la imagen (a), la trayectoria estimada solo se encuentra en la primera mitad de la trayectoria. Esto es debido a que a partir del segundo 4 y hasta el 5, desaparece la textura, lo que provoca que el algoritmo de SD-SLAM no pueda continuar con la estimación de la pose y entre en un estado de relocalización. El algoritmo seguirá en este estado hasta la vuelta donde volverá a pasar por zonas conocidas y podrá relocalizarse, volviendo a estimar la pose en los últimos tramos. Todo esto se traduce en un alto error ATE, ya que hay zonas durante las cuales no se ha producido estimación alguna. En el caso de la versión modificada, Figura 5.3 (b), como era

esperable, se encuentra estimación de la pose a lo largo de toda la trayectoria. Esto es gracias a que durante ese intervalo de 1 segundo donde no se cuenta con textura el nuevo algoritmo pasa a estimar la pose usando DIFODO para ello. Cuando hay textura de nuevo el algoritmo recupera el *tracking* original usando ORB. Es por ello que se encuentra un error mucho más pequeño y cercano al que se obtendría en la secuencia original sin este intervalo sin textura.

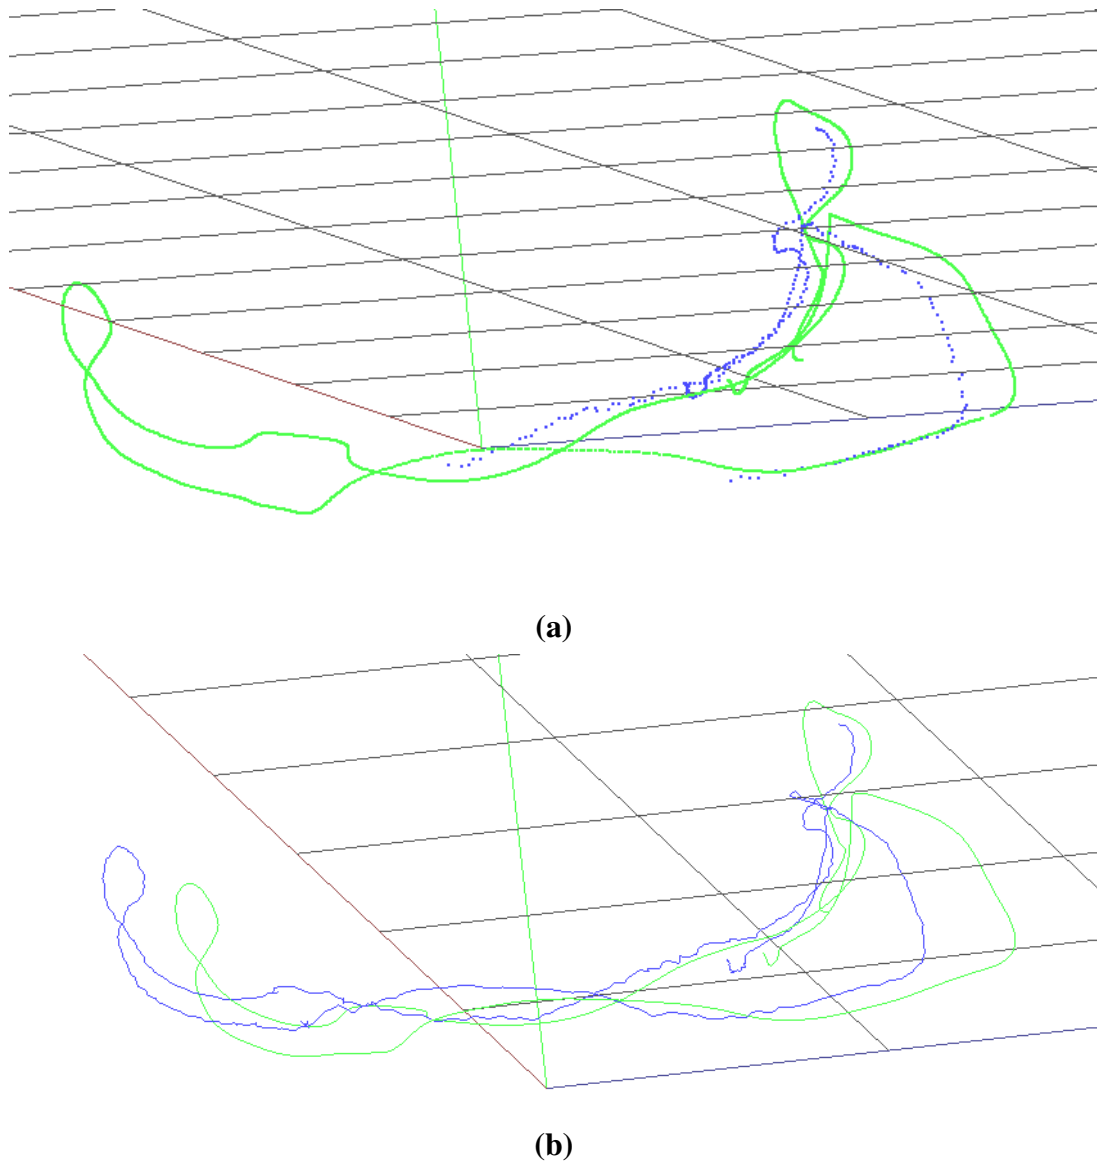


Figura 5.3: Trayectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el *ground-truth*, en azul la trayectoria estimada en cada caso. Las figura (a) corresponde a la versión original de SD-SLAM y la figura (b) a la versión modificada de SD-SLAM, SD-SLAM+

Test 2

- **Intervalos sin textura simulados (segundos):** [4-5, 6-7, 8-9]
- **Descripción:** En esta ocasión se aumenta el número de intervalos sin textura durante la secuencia. El objetivo es ver como se comporta SD-SLAM+ cuando se intercambia entre un algoritmo y otro.

Version	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
SD-SLAM	1.2528	0.8894	0.1415	0.8823	0.0350	2.1653	866.4533
SD-SLAM+	0.1960	0.1781	0.1609	0.0819	0.0335	0.3265	21.2211

Tabla 5.9: Comparación del ATE en el test 2: SD-SLAM vs SD-SLAM+

Los resultados para SD-SLAM siguen siendo los mismos pues desde que deja de hacer estimaciones de pose, en el primer intervalo donde se pierde la textura, no es capaz de relocalizarse. El resto de intervalos de pérdida de textura se producen antes de que la relocalización sea posible por lo que no afectan al error de trayectoria absoluto, siendo el de la Tabla 5.8 el mismo que en la Tabla 5.9.

Una vez más se observa en la Tabla 5.9 como el error en el caso de SD-SLAM+ es bastante menor, gracias a que consigue seguir haciendo *tracking* en los momentos donde no hay textura consiguiendo una trayectoria más parecido a la real.

Test Number	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
Test 1	0.1863	0.1673	0.1199	0.0820	0.0352	0.3153	19.1323
Test 2	0.1960	0.1781	0.1609	0.0819	0.0335	0.3265	21.2211

Tabla 5.10: Test 2: Evolución del ATE en SD-SLAM+

La tabla anterior, Tabla 5.10, muestra como ha evolucionado el error desde el test 1 al test 2. Se aprecia como a pesar de introducir más intervalos donde el *tracking* de DIFODO tiene que entrar en juego apenas el error se ha visto alterado y los resultados son prácticamente similares. Esto es lógico pues ambos algoritmos DIFODO y SD-SLAM tenían un rendimiento similar para esta secuencia como se vió en la sección 5.3 por lo que usar un algoritmo u otro no debería alterar el error en gran medida.

Test 3

- **Intervalos sin textura simulados (segundos):** [4-8]
- **Descripción:** En esta ocasión se va a analizar el comportamiento cuando no hay textura de forma prolongada en el tiempo. El objetivo es ver como se comporta SD-SLAM+ cuando DIFODO se usa de forma prolongada.

Version	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
SD-SLAM	1.2528	0.8894	0.1415	0.8823	0.0350	2.1653	866.4533
SD-SLAM+	0.1289	0.1117	0.0895	0.0643	0.0330	0.3389	9.1240

Tabla 5.11: Comparación del ATE en el test 3: SD-SLAM vs SD-SLAM+

Los resultados para SD-SLAM siguen siendo los mismos por las razones que se vieron en el anterior test.

En la Tabla 5.11 podemos volver a observar como los resultados del SD-SLAM+ son mucho mejores que el algoritmo original.

Test Number	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
Test 1	0.1863	0.1673	0.1199	0.0820	0.0352	0.3153	19.1323
Test 2	0.1960	0.1781	0.1609	0.0819	0.0335	0.3265	21.2211
Test 3	0.1289	0.1117	0.0895	0.0643	0.0330	0.3389	9.1240

Tabla 5.12: Test 3: Evolución del ATE en SD-SLAM+

La tabla anterior, Tabla 5.12, muestra como ha evolucionado el error desde el test 1 al test 3. Es curioso observar la relación del error entre el test 2 y el test 3 pues los intervalos de tiempo en ambos donde no hay textura suman un total de 3 y 4 segundos respectivamente durante un intervalo similar, segundos 4-9 en el test 2 y segundos 4-8 en el test 3. A pesar de ser tan parecidos el error es un 30 % menor en el test 3 frente al test 2. Como se pudo observar en la sección 5.3, en esta secuencia el rendimiento de ambos algoritmos, DIFODO y SD-SLAM es similar por lo que una posible explicación es que en ese intervalo entre los segundos 4-8 de esta secuencia, las estimaciones de pose de DIFODO son mejores o suplen las deficiencias posteriores en la estimación de la pose.

Test 4

- **Intervalos sin textura simulados (segundos):** [4-5, 8-9, 12-13, 16-17]
- **Descripción:** En esta ocasión se aumenta el número de intervalos sin textura durante la secuencia, a lo largo de toda esta. El objetivo es ver como se comporta SD-SLAM+ en las partes finales de la secuencia.

Version	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
SD-SLAM	1.2528	0.8894	0.1415	0.8823	0.0350	2.1653	866.4533
SD-SLAM+	0.3109	0.2845	0.2816	0.1253	0.03501	0.4830	54.5273

Tabla 5.13: Comparación del ATE en el Test 4: SD-SLAM vs SD-SLAM+

Se observa de nuevo en la Tabla 5.13 como el error en el caso de SD-SLAM+ es bastante menor, sin embargo se aprecia un aumento en el error que merece ser estudiado con más detalle comparandolo con los anteriores resultados, esto se aprecia en la siguiente Tabla 5.14:

Test Number	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
Test 1	0.1863	0.1673	0.1199	0.0820	0.0352	0.3153	19.1323
Test 2	0.1960	0.1781	0.1609	0.0819	0.0335	0.3265	21.2211
Test 3	0.1289	0.1117	0.0895	0.0643	0.0330	0.3389	9.1240
Test 4	0.3109	0.2845	0.2816	0.1253	0.0350	0.4830	54.5273

Tabla 5.14: Test 4: Evolución del ATE en SD-SLAM+

En el test 4 se aprecia un aumento del error frente al test 2 de un 50 %. De los cuatro intervalos sin textura de este test, los dos primeros, son parte de los intervalos usados en el test 2, por lo que el aumento del error se debe a los intervalos posteriores. En la Figura 5.4 se puede apreciar como en la parte final la estimación no es tan buena en el test 4, imagen **(b)** comparado con el test 2 en **(a)**. El uso de DIFODO en la parte final parece que no es tan bueno como el de SD-SLAM original, probablemente debido al hecho de que SD-SLAM en esta zona final se apoya más en los cierres de bucle para mejorar sus estimaciones, algo que DIFODO no puede hacer al ser solo odometría.

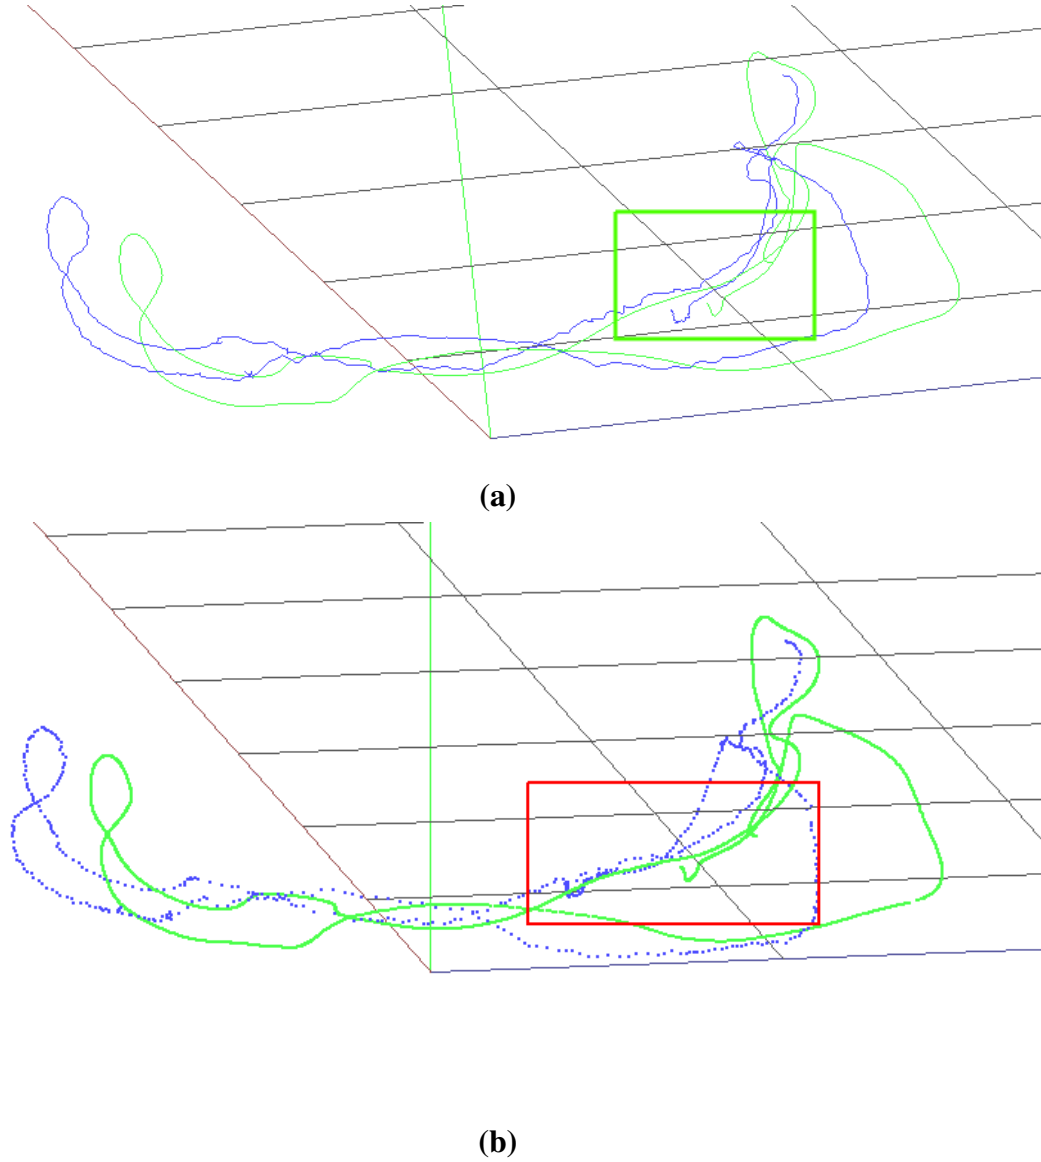


Figura 5.4: Trayectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el *ground-truth*, en azul la trayectoria estimada en cada caso. Las figura (a) corresponde a la estimación de SD-SLAM+ en el test 2 y la figura (b) a la la estimación de SD-SLAM+ en el test 4.

5.4.3. Experimento: Rendimiento de SD-SLAM+ en entornos difíciles

En la sección anterior, se ha evaluado SD-SLAM+ en un entorno donde había mucha información de textura y también de estructura o textura de profundidad. Esto daba como resultado que independientemente del método usado para la estimación de la pose el rendimiento fuera bueno en todos los casos. En concreto en los anteriores test se comprobaba como la falta de textura podía ser suplida por la estructura o información de profundidad de la escena.

En este nuevo experimento, se va a comprobar como se desenvuelve el nuevo SD-SLAM+ en un entorno mucho más difícil donde no hay estructura y se simularán intervalos donde tampoco haya textura. De forma que habrá intervalos de tiempos donde no habrá ni textura ni estructura, un entorno de lo más desafiante.

rgb_dataset_freiburg3_nostructure_texture_far.bag es el nombre de la secuencia que se usará durante los siguientes experimentos. La secuencia consiste, como se puede ver en Figura 5.5, en una serie de papeles con información en ellos que aportan mucha textura en la escena. Por otro lado la única estructura que se encuentra en la escena es un plano que es el suelo. Un plano en estructura es el sinónimo para la textura de una escena completamente homogénea por lo que las estimaciones de DIFODO en este caso tendrán bastante error, como ya se vió en la sección 5.3.




Figura 5.5: SD-SLAM aplicado en **rgb_dataset_freiburg3_nostructure_texture_far.bag**

Es una trayectoria rectilínea, empieza en el punto A y acaba en el punto B sin que haya ninguna relocalización ni posibilidad de ello. Hacia el final de la trayectoria, Figura 5.6, los papeles se pierden de la vista de la cámara quedando solo un cable y el suelo homogéneo. Esto como veremos a continuación supone un problema al *tracking* original de SD-SLAM pues la ausencia de textura impide que este consiga estimar la posición. La secuencia es de 16.1 segundos de duración, sin embargo, aproximadamente los primeros 4 segundos de esta secuencia y del resto,

carecen de imágenes. Esto es así para que a la hora de grabar el hardware tenga un tiempo de estabilización o calentamiento en el arranque, por lo que la duracion real sería de 12 segundos aproximadamente.



Figura 5.6: Final de la secuencia `rgbd_dataset_freiburg3_nostructure_texture_far.bag`

Test 5

- **Intervalos sin textura simulados (segundos):** []
- **Descripción:** No hay intervalos sin textura simulados, ya que la propia secuencia ya presenta una zona hacia el final donde SD-SLAM no encuentra textura suficiente para estimar la posición por lo que DIFODO se usará. Es un buen ejemplo real para comparar sin necesidad de simulaciones el rendimiento del nuevo SD-SLAM+.

Version	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
SD-SLAM	1.3445	0.5417	0.0890	1.2306	0.0136	3.9141	705.07
SD-SLAM+	0.1273	0.1072	0.0941	0.0686	0.0102	0.3038	6.7991

Tabla 5.15: Comparación del ATE en el test 5: SD-SLAM vs SD-SLAM+

Como se observa en la Tabla 5.15, el error es mucho menor en el caso de SD-SLAM+, sin embargo la estimación no es mucho más distinta si nos fijamos visualmente en la Figura 5.7. Unos puntos al final de la Figura 5.7 **(b)** que representan las estimaciones de DIFODO cuando los cables desaparecen de escena es la única diferencia, sin embargo hay una gran diferencia en el error entre ambos algoritmos. Esto se debe a que cuando SD-SLAM se pierde debido a la falta de textura, las siguientes posiciones que estima no se encuentran al final de la secuencia, sino que publica como pose el origen. Esto provoca que cuando se calcule al ATE se esten comparando posiciones del final de la secuencia con el inicio por lo que el error crece muchísimo. Esto se aprecia en el valor máximo de 3.9m de la Tabla 5.15, que corresponde a la comparación entre las posición finales y las poses del origen cuando SD-SLAM está perdido. También se aprecia en como el error medio de SD-SLAM es muy pequeño y similar al de SD-SLAM+ pero al contar con estas errores finales tan grandes la media y el rmse se ven afectados.

SD-SLAM+ ayuda a seguir estimando posiciones en el final de la trayectoria lo que evita que el error crezca y se mantenga estable. Aunque, como se aprecia en la Figura 5.7 **(b)**, las estimaciones no son muy acertadas como en el experimento anterior Subsección 5.4.2 debido a la ausencia de estructura de esta secuencia.




Figura 5.7: Trayectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el *ground-truth*, en azul la trayectoria estimada en cada caso. Las figura (a) corresponde a la estimación de SD-SLAM y la figura (b) a la la estimación de SD-SLAM+.

Test 6

- **Intervalos sin textura simulados (segundos):** [4-5]
- **Descripción:** En este nuevo test se pretende poner aún más a prueba a SD-SLAM+ añadiendo un intervalo durante el cual no hay textura.

Version	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
SD-SLAM	2.5749	2.0802	2.2577	1.5174	0.0140	4.3386	2731.6205
SD-SLAM+	0.3109	0.2845	0.2816	0.1253	0.0350	0.4830	54.5273

Tabla 5.16: Comparación del ATE en el test 6: SD-SLAM vs SD-SLAM+

De nuevo el error cometido por SD-SLAM+ es mucho menor. En este caso SD-SLAM no ha sido capaz de continuar con la estimación a partir del intervalo en el que la textura se pierde. Como la secuencia no presenta posibles relocalizaciones no se vuelve a estimar la posición como se aprecia en la figura Figura 5.8 y la Figura 5.9 de forma visual.

En el caso de SD-SLAM+ el error cometido es mucho menor, sin embargo se pueden apreciar en la zona resaltada de la Figura 5.8 **(b)**, una serie de estimaciones que se acumulan. Al no contar con más estructura que el plano del suelo, las estimaciones de DIFODO no son muy fiables y las nuevas estimaciones no siguen la trayectoria sino que se acumulan en torno al último punto conocido. Sin embargo como es solo un segundo cuando se recupera la textura es capaz de seguir utilizando el *tracking* original de SD-SLAM y la estimación global es mucho mejor que con SD-SLAM.




Figura 5.8: Trayectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el *ground-truth*, en azul la trayectoria estimada en cada caso. Las figura **(a)** corresponde a la estimación de SD-SLAM y la figura **(b)** a la la estimación de SD-SLAM+.

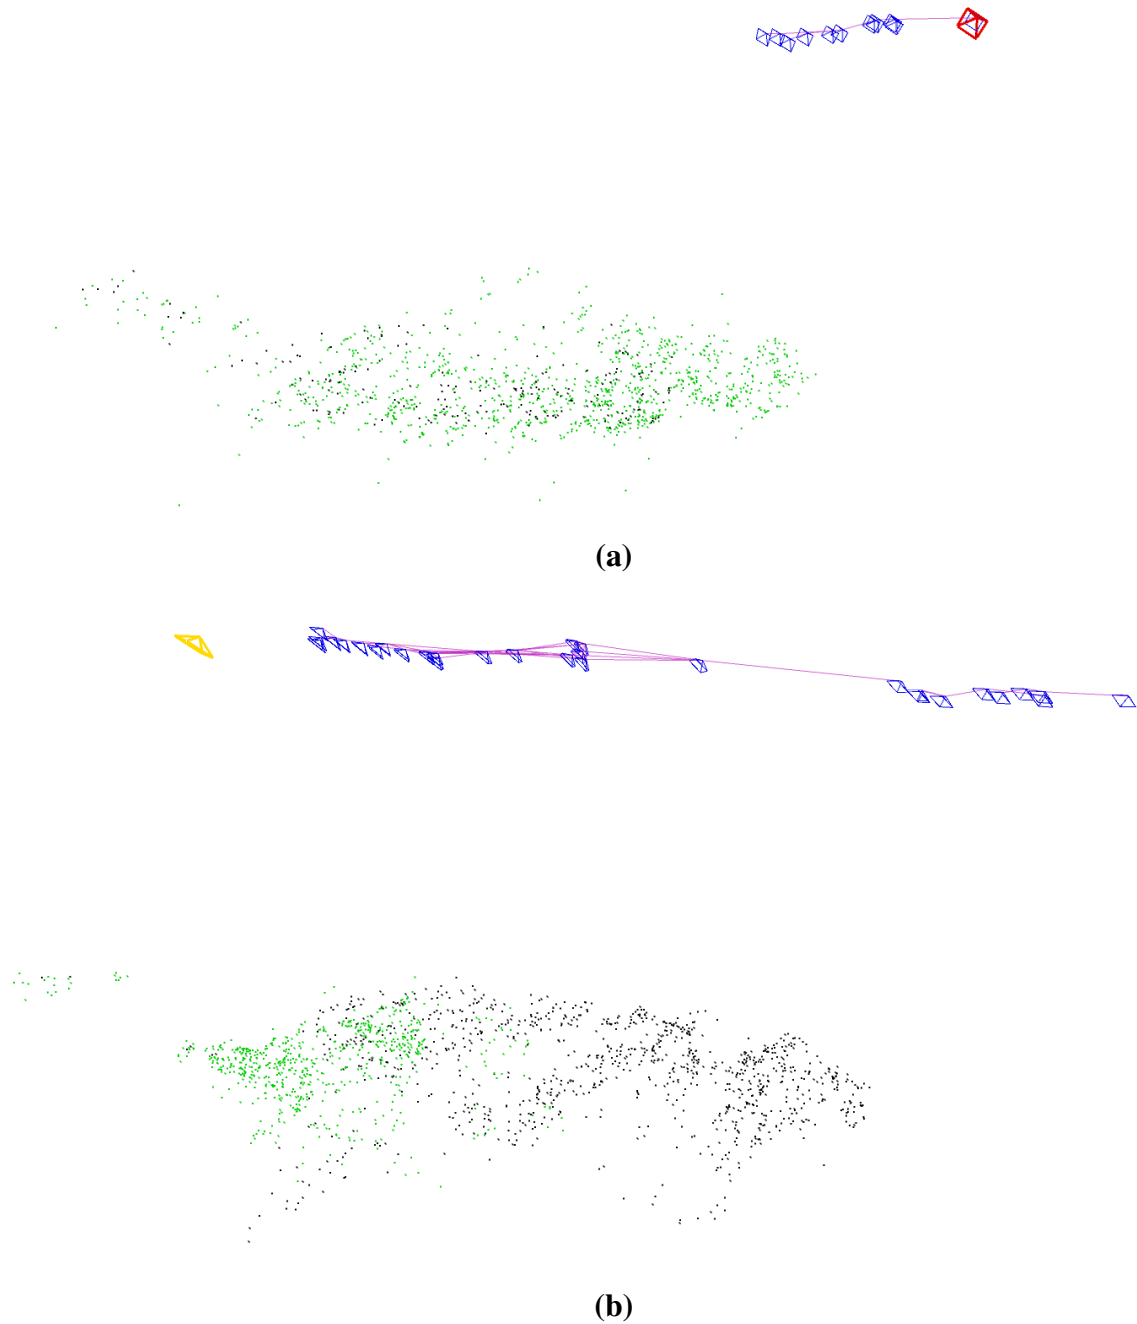


Figura 5.9: Trayectorias y reconstrucción de los algoritmos en la interfaz SD-SLAM. Las figura (a) corresponde a D-SLAM y la figura (b) a SD-SLAM+.

En la Tabla 5.17 se compara el rendimiento de SD-SLAM+ en el test 5 y el test 6. En esta se observa como introducir tan solo un segundo en el *tracking* aumenta el error en casi un 300 %.

5.4. SD-SLAM FRENTE A SD-SLAM+

El error medio pasa a ser de casi 0.30m frente a los 0.10m de la secuencia original en el test 5. Este aumento de 20cm en el error viene dado por ese segundo de intervalo donde la posición casi no avanza debido a la mala estimación de DIFODO, mientras que en la secuencia original durante ese segundo se avanzarán estos 20cm. Esto produce que las estimaciones de SD-SLAM vayan por detrás de la secuencia original 20cm para el resto de estimaciones aumentando el error en esta cantidad.

Test Number	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
Test 5	0.1273	0.1072	0.0941	0.0686	0.0102	0.3038	6.7991
Test 6	0.3109	0.2845	0.2816	0.1253	0.0350	0.4830	54.5273

Tabla 5.17: Test 6: Evolución del ATE en SD-SLAM+

Test 7

- **Intervalos sin textura simulados (segundos):** [4-5, 6-7, 8-9]
- **Descripción:** Se añaden hasta 3 intervalos donde no hay textura.

Version	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
SD-SLAM	2.5749	2.0802	2.2577	1.5174	0.0140	4.3386	2731.6205
SD-SLAM+	0.5854	0.4761	0.5655	0.3406	0.0098	1.0465	148.4094

Tabla 5.18: Comparación del ATE en el test 7: SD-SLAM vs SD-SLAM+

El rendimiento de SD-SLAM sigue siendo el mismo que en el test anterior como era de esperar al no poder relocalizarse. De nuevo SD-SLAM+ lo hace mejor como era de esperar. Aunque el rendimiento no es para nada bueno, casi 0.5m de error medio por posición, algo que para algoritmos de SLAM es demasiado. Se puede visualizar en la Figura 5.10 (b) como la trayectoria que se sigue esta vez es mucho más irregular que la que se observaba en el test anterior Figura 5.10 (a). Cada vez que hay un intervalo donde se utiliza DIFODO, se observa o bien una acumulación de puntos o un desvío en la trayectoria original. Es interesante observar como en el último intervalo, se produce una rotación en la orientación por parte de DIFODO que produce que el *tracking* de SD-SLAM, una vez recuperada la información visual, estime

un desplazamiento rectilíneo pero en una dirección incorrecta, alejando aún más las siguientes estimaciones.




Figura 5.10: Trayectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el *ground-truth*, en azul la trayectoria estimada en cada caso. Las figura (a) corresponde a la estimación de SD-SLAM+ para el test 6 y la figura (b) a la la estimación de SD-SLAM+ para el test 7.

Test 8

- **Intervalos sin textura simulados (segundos):** [4-9]
- **Descripción:** Esta vez se va a probar como afecta un largo intervalo durante el cual no hay textura en esta secuencia que tampoco cuenta con estructura.

5.4. SD-SLAM FRENTE A SD-SLAM+

Test Number	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
Test 5	0.1273	0.1072	0.0941	0.0686	0.0102	0.3038	6.7991
Test 6	0.3109	0.2845	0.2816	0.1253	0.0350	0.4830	54.5273
Test 7	0.5854	0.4761	0.5655	0.3406	0.0098	1.0465	148.4094
Test 8	0.9999	0.7783	0.7649	0.6277	0.0131	1.6505	383.9896

Tabla 5.19: Test 8: Evolución del ATE en SD-SLAM+

El error que se obtiene en este test 8 es de cerca del 0.8m de media como se aprecia en Tabla 5.19. Como era de esperar para esta secuencia cuanto más tiempo se esté estimando posiciones con DIFODO mayor va a ser el aumento del error. En la Tabla 5.19 se aprecia como según se ha ido aumentando el tiempo donde se utilizaba DIFODO el error ha ido aumentando. En la Figura 5.11 se puede visualizar como con la inclusión en cada nuevo test de un mayor intervalo de tiempo sin textura, los estimaciones han ido degradándose.




Figura 5.11: Comparativa de las trayectorias de los algoritmos mostradas en el programa slam-testbed. En verde se muestra el *ground-truth*, en azul la trayectoria estimada en cada caso.

5.4.4. Experimento: Rendimiento de SD-SLAM+ en entornos con zonas de baja textura

En este experimento se comprueba SD-SLAM en un entorno real, donde en determinado momento, el algoritmo original se pierde, siendo incapaz de estimar nuevas posiciones debido a la falta de textura. Este experimento muestra un caso real donde se pierde la textura de forma natural algo que ocurre con cierta frecuencia en ciertos entornos.

rgbd_dataset_freiburg3_floor.bag es el nombre de la secuencia evaluada en este experimento. Es una secuencia de larga duración, de 49.3 segundos donde los primeros 4 segundos de nuevo no cuentan con imágenes. La secuencia es una trayectoria circular mientras se recorre una habitación con diversos objetos que aportan mucha textura y estructura. Sólo hay un momento donde el aporte de textura decae como se aprecia en . Al ser una trayectoria circular, por el final de la secuencia se vuelve a visitar una zona ya conocida buscando producir un cierre de bucle.



Figura 5.12: Momento en el cual la textura decae en la secuencia **rgbd_dataset_freiburg3_floor.bag**. Imagen perteneciente a la GUI de SD-SLAM+

Test 9

Es este test no ha habido necesidad de simular la perdida de textura como en los tests anteriores, sino, que como se ha mostrado en la figura anterior, de por si la secuencia cuenta con una zona donde la textura es bastante pobre. Esto produce que el algoritmo original SD-SLAM se pierda desde ese momento hasta volver a una zona conocida unos segundos después.

Version	rmse (m)	mean (m)	median (m)	std (m)	min (m)	max (m)	sse (m)
SD-SLAM	0.2909	0.1705	0.1022	0.2192	0.0195	1.2202	98.2218
SD-SLAM+	0.1111	0.1042	0.1011	0.0385	0.0267	0.2188	15.9222

Tabla 5.20: Comparación del ATE en el test 9: SD-SLAM vs SD-SLAM+

En la tabla 5.20 se hace una comparación entre las dos versiones de SD-SLAM. Como consecuencia de esta perdida de textura hacia el final de la secuencia, SD-SLAM tiene un error medio y de mínimos cuadrados mucho más alto que la versión mejorada SD-SLAM+. Sin embargo, si uno se fija en la mediana se obtienen valores casi idénticos. Esto es así puesto que ambos algoritmos utilizan la información o la estimación de pose de SD-SLAM hasta que se llega a la zona de la figura 5.12. En ese punto, SD-SLAM se pierde incapaz de hacer una estimación correcta en la pose debido a la ausencia de textura y empieza a acumular error hasta el momento de relocalizarse hacia el final de la secuencia. Esto se puede observa en el error máximo para SD-SLAM de 1.22m frente a los 0.21m de error máximo de SD-SLAM+.

Por otro lado, SD-SLAM+ mantienen constante su estimación, siendo la media, mediana y el error por mínimos cuadrados muy similares, en torno a los 0.10m de error. Esto lo consigue utilizando la estimación de pose de DIFODO en el momento donde SD-SLAM no es capaz de estimar la pose.

No solo el error se ve afectado, pues mientras que SD-SLAM se encuentra perdido, este no es capaz de hacer el mapeado hasta que se reencuentra de nuevo, por lo que perdidas de textura momentaneas afectan negativamente a la reconstrucción de entornos 3D también, como se puede ver en la figura 5.13. Existe una zona recuadrada en rojo en la cual no hay puntos en el espacio puesto que durante esa parte el algoritmo se encontraba perdido intentando relocalizarse.




Figura 5.13: Comparativa de las trayectorias y reconstrucción de los algoritmos SD-SLAM y SD-SLAM+.

5.4.5. Evaluación de tiempo de procesamiento

A continuación, en esta sección se va a evaluar el coste computacional de añadir DIFODO a SD-SLAM, comparando los tiempos de procesamiento de SD-SLAM y SD-SLAM+. Para ello se va a utilizar la secuencia utilizada en el anterior **Test 9, rgb_dataset_freiburg3_floor.bag**. Para este experimento, se ha usado DIFODO con una resolución de 320x240 y cinco niveles de pirámide.

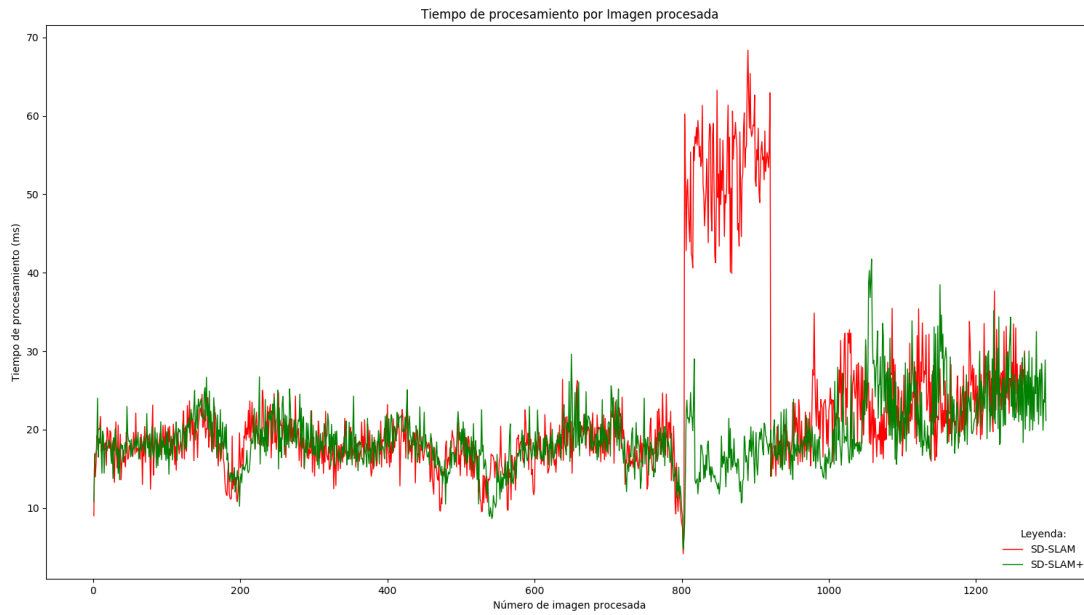


Figura 5.14: Comparativa del tiempo de procesamiento por imagen para la secuencia **rgbd_dataset_freiburg3_floor.bag**

La figura anterior 5.14, representa el tiempo de procesamiento por imagen para la secuencia **rgbd_dataset_freiburg3_floor.bag**, con una duración de 1360 imágenes o *frames*. El tiempo de procesamiento por *frame* es similar para ambos, SD-SLAM y SD-SLAM+, manteniéndose durante casi toda la secuencia en torno a los 20ms. Sin embargo, se observa un periodo donde hay un aumento importante del tiempo de procesamiento para SD-SLAM, de la imagen 800 a la 950 aproximadamente. Durante estos 5 segundos, SD-SLAM pasa a tener un tiempo de procesamiento del doble con respecto al resto de la secuencia, sobrepasando los 30ms que precisa el tiempo real. La razón de este aumento es que SD-SLAM se pierde, imposibilitándole la estimación de nuevas poses, debido a la falta de textura en la escena, como se discutió en el anterior **Test 9**.

Cuando SD-SLAM se pierde, este pasa al modo de relocalización, intentando relocalizarse con las nuevas imágenes que le llegan, utilizando todos los *keyframes* guardados que tiene en el mapa para buscar emparejarlos. Este es un proceso costoso pues si hay muchos *keyframes* con características similares, el proceso de intentar emparejar la imagen actual con cada uno de esos puede llegar a consumir más tiempo del deseado, como en este caso.

Por otro lado SD-SLAM+ al no perderse por usar DIFODO durante ese periodo donde no hay textura, evita entrar en ese modo de relocalización. Se puede apreciar el tiempo de procesamien-

to de DIFODO a partir de la imagen número 800 durante unas 30 imágenes aproximadamente, con un tiempo medio de procesamiento de unos 20ms, similar al que se obtiene con la estimación original de SD-SLAM.

Integrar DIFODO junto a SD-SLAM, no solo no incrementa el coste computacional, sino que lo reduce al evitar entrar en este modo de relocalización. Mientras que la textura se mantenga, el algoritmo original no se verá afectado computacionalmente pues DIFODO solo añade tiempo computacional cuando el *tracking* original de SD-SLAM falla. En la práctica cuando se usa DIFODO el tracking de SD-SLAM original no se usa, por lo que al sustituir uno con otro el tiempo de procesamiento se mantiene estable.

5.4.6. Conclusiones

En este capítulo se ha visto como DIFODO es un algoritmo que puede integrarse con SD-SLAM para hacer a este último más robusto frente a situaciones donde falta textura visual. Esto es así, pues cumple con los requisitos de ser un algoritmo de odometría visual que sólo usa información de profundidad y cumple con el requisito de procesamiento en tiempo real.

Se ha comprobado como SD-SLAM es mejor que DIFODO en la mayoría de los casos siempre y cuando la imagen presente información de textura y de estructura suficientes. Sin embargo cuando hay ausencia de textura en la imagen, pero suficiente estructura, DIFODO estima la posición con un menor error que SD-SLAM, el cual directamente no estima posición alguna.

Por otro lado, ambos algoritmos fallan cuando no hay estructura ni textura por lo que SD-SLAM+ precisará de al menos estructura o textura en la escena en todo momento para funcionar correctamente.

Finalmente, se ha comparado SD-SLAM contra SD-SLAM+, viendo como en aquellos casos donde hay ausencia de textura en algún momento, SD-SLAM+ tiene un mejor rendimiento al ser capaz de estimar la posición frente a un SD-SLAM que se pierde y solo es capaz de volver a estimar posiciones si se da un cierre de bucle.

En conclusión la integración de DIFODO en SD-SLAM solo trae ventajas y no conlleva ninguna desventaja pues computacionalmente no solo no implica un mayor tiempo de procesamiento sino que ayuda a evitar el elevado tiempo de procesamiento que conlleva el intentar relocalizarse.

Capítulo 6

Conclusiones

6.1. Objetivos conseguidos

6.2. Discusión

6.3. Trabajos futuros

Bibliografía

- [1] Jean-Yves Bouguet et al. Pyramidal implementation of the affine lucas kanade feature tracker description of the algorithm. *Intel Corporation*, 5(1-10):4, 2001.
- [2] M. Jaimez and J. Gonzalez-Jimenez. Fast visual odometry for 3-d range sensors. *IEEE Transactions on Robotics*, 31(4):809–822, 2015.
- [3] Hagen Spies, Bernd Jähne, and John L. Barron. Range flow estimation. *Computer Vision and Image Understanding*, 85(3):209 – 231, 2002.
- [4] J. Sturm, W. Burgard, and D. Cremers. Evaluating egomotion and structure-from-motion approaches using the TUM RGB-D benchmark. In *Proc. of the Workshop on Color-Depth Camera Fusion in Robotics at the IEEE/RJS International Conference on Intelligent Robot Systems (IROS)*, Oct. 2012.